مكتب التكوين المهني و إنعاش الشغل
Office de la Formation Professionnelle et de la Promotion du Travail

Direction Régionale TTA
Année de Formation : 2026-2027

FILIÈRE INTELLIGENCE ARTIFICIELLE · OPTION ASSISTANT DATA ANALYST

Projet de synthèse

De la donnée brute à la décision

Analyse des commandes et des messages clients de MarocShop

Module M201 — Approfondir les Systèmes Décisionnels

Formateur	Pr. SADRATI ZAKARIAE
Séances couvertes	Séances 1 à 6 du module M201
Niveau	Intermédiaire : de l'application guidée vers l'analyse autonome
Modalité	Individuel ou en binôme
Durée estimée	Environ 12 heures de travail
Outils	Excel et Python (pandas, numpy, matplotlib, scikit-learn)
Données fournies	commandes.csv · messages_clients.csv
Livrables	Classeur Excel, notebook Python, jeux de données nettoyés, rapport de synthèse

1. Contexte et mission

MarocShop est une boutique en ligne marocaine qui vend cinq familles de produits (électronique, mode, maison, beauté, sport) dans sept grandes villes du pays. La direction constate trois problèmes :

- un **taux de retours** de colis qu'elle juge trop élevé ;
- des colis qui **arrivent abîmés**, sans que l'on sache d'où vient le problème ;
- une messagerie client **polluée par des spams**, qui noie les vraies demandes.

Vous êtes recruté(e) comme **Assistant Data Analyst**. Votre mission : fiabiliser les données, les décrire, repérer les anomalies, estimer les risques et formuler des **recommandations chiffrées** à la direction.

> **Attention**
> Les deux fichiers sont **fictifs** et créés pour cette formation. Ils sont volontairement **bruts** : comme dans la réalité, ils contiennent des erreurs. Cet énoncé ne les liste pas, c'est à vous de les trouver et de les traiter avec méthode.

Compétences visées

- Identifier la population, les individus et les types de variables, et distinguer statistique descriptive et inférentielle.
- Calculer et interpréter les mesures centrales, de dispersion et de position.
- Détecter, expliquer et traiter les valeurs aberrantes avec plusieurs méthodes (2 écarts-types, IQR, Tukey, box plot, Z-score, DBSCAN, Isolation Forest).
- Choisir entre standardisation et normalisation selon l'usage.
- Calculer des probabilités conditionnelles, appliquer le théorème de Bayes, construire un classificateur Naive Bayes et mener une simulation Monte Carlo.
- Transformer des résultats chiffrés en décisions argumentées.

Plan du projet

Partie	Thème	Séance	Notions mobilisées	Durée	Points
1	Découverte, types de variables, nettoyage	S1	Population, individu, caractère ; types de variables ; descriptive vs inférentielle ; qualité des données	1 h 30	3
2	Mesures centrales	S1	Moyenne, médiane, mode ; Excel et Python	1 h	2
3	Mesures de dispersion	S2	Étendue, variance, écart-type	1 h 15	2
4	Mesures de position et premiers outliers	S3	Quartiles, déciles, centiles ; causes et impact des outliers ; méthode des deux écarts-types	1 h 30	2
5	Détection et traitement des outliers	S4	IQR, Tukey, box plot, Z-score ; remplacer, supprimer ou conserver	1 h 45	3
6	Mise à l'échelle et détection multivariée	S5	Standardisation, normalisation, DBSCAN, Isolation Forest	1 h 45	2,5
7	Probabilités et classification	S6	Probabilité conditionnelle, Bayes, Naive Bayes, Monte Carlo	2 h 30	3,5
8	Synthèse décisionnelle	S1–S6	Rapport, indicateurs clés, recommandations	1 h	2
	Total			≈ 12 h	20

2. Les données fournies

Fichier 1 : commandes.csv

Environ 500 lignes. **Une ligne = une commande** passée en 2025 sur MarocShop.

Colonne	Description	Exemple
id_commande	Identifiant de la commande	CMD0001
date_commande	Date de la commande	2025-01-03
ville	Ville de livraison	Tanger
sexe	Sexe du client	Femme
age_client	Âge du client, en années	35
categorie	Famille de produits commandée	Mode
canal	Canal de commande (Web, Application, Téléphone)	Application
nb_articles	Nombre d'articles dans la commande	3
montant_dh	Montant total de la commande, en dirhams	386.10
entrepot	Entrepôt d'expédition (A, B ou C)	B
delai_livraison_jours	Délai de livraison, en jours	3
colis_endommage	Le colis est-il arrivé endommagé ? (Oui / Non)	Non
satisfaction	Niveau de satisfaction : Faible, Moyen ou Élevé	Moyen
retour_client	Le client a-t-il retourné le colis ? (Oui / Non)	Non

Fichier 2 : messages_clients.csv

Environ 330 lignes. **Une ligne = un message** reçu par le service client (français, anglais, quelques mots en darija translittérée).

Colonne	Description	Exemple
id_message	Identifiant du message	MSG0001
date_message	Date de réception	2025-03-13
Category	Étiquette : ham (message légitime) ou spam (indésirable)	ham
Message	Texte du message	Quel est le délai de livraison pour Fès ?

Règles d'utilisation

- **Ne modifiez jamais les fichiers d'origine.** Travaillez sur des copies et gardez les originaux intacts.
- Format : séparateur virgule, décimales avec un point, encodage UTF-8. Dans Excel : Données > À partir du texte/CSV, origine « 65001 : Unicode (UTF-8) ». En Python : `pd.read_csv("commandes.csv")`.
- Dès qu'un tirage aléatoire intervient, fixez la graine : `np.random.seed(42)` et `random_state=42`, pour que vos résultats soient reproductibles.
- Nommez les fichiers intermédiaires exactement comme demandé : `commandes_nettoye.csv` (fin de la partie 1) et `commandes_propre.csv` (fin de la partie 5).

3. Livrables et organisation

Livrable	Contenu	Nom du fichier
Classeur Excel	Un onglet par partie (P1 à P8), tableaux de résultats avec formules visibles, au moins 3 graphiques	Projet_M201_NOM_Prenom.xlsx
Notebook Python	Code commenté, exécutable de haut en bas, résultats et graphiques affichés	Projet_M201_NOM_Prenom.ipynb
Jeux de données	Fichier nettoyé (fin P1) et fichier propre (fin P5)	commandes_nettoye.csv, commandes_propre.csv
Rapport	3 pages maximum, Word ou PDF (partie 8)	Rapport_M201_NOM_Prenom.docx

Répartition des outils. Les parties 2, 3 et 4 sont réalisées **dans Excel et dans Python** : les deux résultats doivent concorder. Les parties 5 et 6 se font en Python. La partie 7 se fait en Python (les questions 7.1 à 7.4 peuvent aussi être faites avec un tableau croisé dynamique Excel).

Règle d'or. Un chiffre sans phrase d'interprétation ne vaut presque rien : après chaque tableau, écrivez une à deux phrases comme si vous parliez à la direction.

Partie 1 — Découverte, types de variables et nettoyage

Séance 1 · Durée estimée : 1 h 30 · Barème : 3 points · Outils : Excel + Python

Objectif. Comprendre ce que contiennent les données, classer correctement les variables et obtenir un jeu de données fiable pour la suite.

> **Rappel du cours**
> Une variable est **qualitative** (nominale : sans ordre ; ordinale : avec ordre) ou **quantitative** (discrète : on compte ; continue : on mesure).
> La **statistique descriptive** décrit un jeu de données ; la **statistique inférentielle** généralise d'un échantillon à la population.

Travail demandé

Q1.1 Chargez les deux fichiers (Python et Excel). Pour chacun, relevez le nombre de lignes et de colonnes, les types détectés et le nombre de valeurs manquantes par colonne.

```
import pandas as pd
cmd = pd.read_csv("commandes.csv")
msg = pd.read_csv("messages_clients.csv")
print(cmd.shape); cmd.info(); print(cmd.isna().sum())
```

Q1.2 Pour `commandes.csv`, précisez la **population**, l'**individu** (unité statistique) et trois exemples de **caractères**. Faites de même pour `messages_clients.csv`.

Q1.3 Complétez le tableau de classification. Choisissez parmi : qualitative nominale, qualitative ordinale, quantitative discrète, quantitative continue. Justifiez chaque choix en une phrase. (`id_commande` est un identifiant, pas une variable d'analyse.)

Variable	Type	Justification
date_commande		
ville		
sexe		
age_client		
categorie		
canal		
nb_articles		
montant_dh		
entrepot		
delai_livraison_jours		
colis_endommage		
satisfaction		
retour_client		
Category (messages)		

Q1.4 Auditez la qualité des deux fichiers et remplissez le **journal des anomalies**. Types d'anomalies à rechercher :

- doublons exacts (`duplicated().sum()`) ;
- valeurs manquantes ;
- modalités écrites de plusieurs façons : affichez `value_counts()` de chaque variable qualitative et regardez la casse, les espaces et les accents ;
- formats de date différents ;
- valeurs impossibles ou suspectes : utilisez `describe()` et regardez les minimums et maximums.

Colonne	Type d'anomalie	Nombre	Comment l'avez-vous trouvée ?	Décision

Q1.5 Nettoyez une **copie** de `commandes.csv` :

- supprimez les doublons exacts ;
- harmonisez les variables qualitatives pour que chaque modalité n'ait qu'une seule écriture ;
- convertissez `date_commande` en vrai type date (attention aux deux formats présents) et créez une colonne `mois` ;
- traitez les valeurs manquantes en justifiant votre choix colonne par colonne : suppression de la ligne, remplacement par la médiane ou le mode, ou modalité « Non renseigné ».

Attention
Ne traitez pas encore les valeurs numériques extrêmes ou impossibles (âges, montants, délais, nombres d'articles). Elles servent aux parties 2 à 5 et seront traitées en partie 5. Corrigez seulement les doublons, les textes, les dates et les valeurs manquantes.

Q1.6 Statistique descriptive ou inférentielle ? Justifiez pour chaque situation :

- (a) calculer le montant moyen des commandes du fichier ;
- (b) à partir de 100 commandes tirées au hasard, estimer le montant moyen de toutes les commandes futures ;
- (c) représenter la répartition des commandes par ville.

Livrable attendu
`commandes_nettoye.csv` · tableau de classification · journal des anomalies · petit tableau « avant / après » (nombre de lignes, nombre de valeurs manquantes) · réponses à Q1.2 et Q1.6.

Partie 2 — Mesures centrales

Séance 1 · Durée estimée : 1 h · Barème : 2 points · Outils : Excel + Python

Objectif. Résumer chaque variable par sa « valeur typique » et choisir la bonne mesure.

> **Rappel du cours**
> **Moyenne** = somme des valeurs ÷ nombre de valeurs. **Médiane** = valeur qui coupe la série ordonnée en deux moitiés égales. **Mode** = valeur la plus fréquente.
> Excel : `MOYENNE`, `MEDIANE`, `MODE.SIMPLE`. Python : `statistics.mean / median / mode` ou les méthodes pandas.

Travail demandé

Q2.1 Sur `commandes_nettoye.csv`, calculez la moyenne, la médiane et le mode de `age_client`, `nb_articles`, `montant_dh` et `delai_livraison_jours` dans Excel **et** Python. Vérifiez que les deux outils donnent les mêmes valeurs.

Variable	Moyenne	Médiane	Mode	Excel = Python ?	Remarque
age_client					
nb_articles					
montant_dh					
delai_livraison_jours					

Q2.2 Comparez la moyenne et la médiane de `montant_dh`, puis de `delai_livraison_jours`. Que remarquez-vous ? Quelle mesure donneriez-vous à la direction pour dire « une commande typique vaut… » ? Justifiez (pensez à l'exemple des salaires et des primes vu en cours).

Q2.3 Calculez le mode de `ville`, `categorie`, `canal` et `satisfaction`. Pourquoi ne peut-on pas calculer la moyenne de ces variables ? Quelle autre mesure centrale a un sens pour `satisfaction`, qui est ordinale ?

Q2.4 Calculez le montant moyen **et** médian par catégorie (`groupby` ou tableau croisé dynamique) et représentez-les par un diagramme en barres. Quelle catégorie rapporte le plus par commande ?

> **Conseil**
> Gardez précieusement ces valeurs : vous les comparerez à celles obtenues après traitement des valeurs aberrantes en partie 5.

> **Livrable attendu**
> Tableau Q2.1 · diagramme Q2.4 · 5 lignes d'interprétation maximum.

Partie 3 — Mesures de dispersion

Séance 2 · Durée estimée : 1 h 15 · Barème : 2 points · Outils : Excel + Python

Objectif. Mesurer à quel point les valeurs s'éloignent les unes des autres, et comprendre la sensibilité de ces mesures aux valeurs extrêmes.

> **Rappel du cours**

Étendue = max − min. **Variance** d'échantillon : $\sigma^2 = \Sigma(x_i - \bar{x})^2 \div (n - 1)$. **Écart-type** = √variance, exprimé dans la même unité que les données.
Excel : `VAR.S` et `ECARTYPE.STANDARD`. Python : pandas (`.var()`, `.std()`) divise par n − 1, mais numpy (`np.var`, `np.std`) divise par n par défaut : ajoutez `ddof=1` pour retrouver la formule du cours.

Travail demandé

Q3.1 Pour `montant_dh`, `age_client` et `delai_livraison_jours`, calculez l'étendue, la variance et l'écart-type dans Excel **et** Python.

Variable	Étendue	Variance	Écart-type	Excel = Python ?
montant_dh				
age_client				
delai_livraison_jours				

Q3.2 Calcul **pas à pas** sur les 6 premières commandes pour `delai_livraison_jours` : (a) moyenne ; (b) écarts à la moyenne ; (c) carrés des écarts ; (d) variance avec n − 1 ; (e) écart-type. Faites-le dans Excel avec des colonnes intermédiaires, puis vérifiez avec `VAR.S` et `ECARTYPE.STANDARD`.

Q3.3 Calculez l'écart-type du délai de livraison **par ville**. Quelle ville a les délais les plus réguliers ? Les plus imprévisibles ? Une ville vous semble-t-elle avoir une dispersion anormalement forte : phénomène réel ou effet de valeurs extrêmes ? (Vous y reviendrez en partie 5.)

Q3.4 Mesurez la sensibilité : calculez l'étendue et l'écart-type de `montant_dh` avant et après avoir retiré les 5 plus grandes valeurs. De combien de % l'écart-type change-t-il ? Que concluez-vous sur les limites de ces indicateurs ?

Q3.5 Les montants des commandes sont-ils homogènes ou hétérogènes ? Argumentez en comparant l'écart-type à la moyenne. (**Bonus** : calculez le coefficient de variation = écart-type ÷ moyenne.)

Livrable attendu
Tableau Q3.1 · calcul détaillé Q3.2 · tableau des écarts-types par ville · réponses rédigées Q3.3 à Q3.5.

Partie 4 — Mesures de position et premiers outliers

Séance 3 · Durée estimée : 1 h 30 · Barème : 2 points · Outils : Excel + Python

Objectif. Situer une valeur par rapport aux autres, puis repérer, expliquer et mesurer l'influence des premières valeurs aberrantes.

Rappel du cours
Quartiles : Q1 (25 %), Q2 (50 %, la médiane), Q3 (75 %). **Déciles** : D1 à D9 (10 % à 90 %). **Centiles** : C1 à C99.
Une **valeur aberrante** (outlier) est une observation à une distance anormale des autres : événement rare ou erreur. Elle fausse la moyenne et la dispersion.
Méthode des deux écarts-types : seuils = moyenne ± 2σ, adaptée à une distribution normale.
Excel : `QUARTILE.INCLURE`, `CENTILE.INCLURE`. Python : `np.percentile` ou `Series.quantile`.

Travail demandé

Q4.1 Pour `montant_dh`, calculez Q1, Q2, Q3, D1, D5, D9, C95 et C99 dans Excel **et** Python.

	Q1	Q2	Q3	D1	D5	D9	C95	C99
Excel								
Python								

Q4.2 Rédigez trois phrases d'interprétation du type « 25 % des commandes ont un montant inférieur ou égal à … ». Que vaut D5 par rapport à la médiane ?

Q4.3 Tracez l'histogramme de `montant_dh` avec trois lignes verticales (Q1, D5 et C95) grâce à `plt.axvline`. Décrivez la forme. Si l'histogramme est écrasé, tracez-en un second limité à la zone principale : pourquoi le premier est-il écrasé ?

Q4.4 Repérage simple par minimum et maximum : pour `age_client`, `nb_articles`, `montant_dh` et `delai_livraison_jours`, listez les 5 plus petites et les 5 plus grandes valeurs (Excel : tri et filtre ; Python : `nsmallest` / `nlargest`). Remplissez le **registre des valeurs suspectes** (8 lignes minimum). Cause probable à choisir parmi : erreur de saisie humaine, erreur de mesure, erreur de traitement des données, erreur intentionnelle, erreur d'échantillonnage, valeur naturelle (événement rare).

ID commande	Variable	Valeur	Possible ou impossible ?	Cause probable

Q4.5 Appliquez la **méthode des deux écarts-types** à `montant_dh` et `age_client` : moyenne, écart-type, seuils bas et haut, nombre et liste des valeurs détectées. Tracez un nuage de points avec des lignes horizontales pour la moyenne et les deux seuils.

Q4.6 Réflexion :

- (a) Les valeurs extrêmes influencent-elles la moyenne et l'écart-type qui servent à calculer les seuils ? Que se passe-t-il pour les seuils si vous retirez les valeurs aberrantes puis recalculez ?
- (b) Cette méthode suppose une distribution normale : `montant_dh` respecte-t-elle cette condition (observez l'histogramme) ? Quel risque cela crée-t-il ?

Livrable attendu
Tableau Q4.1 · histogramme Q4.3 · registre des valeurs suspectes · graphique et conclusion Q4.5 · réponses Q4.2 et Q4.6.

Partie 5 — Détection et traitement des outliers

Séance 4 · Durée estimée : 1 h 45 · Barème : 3 points · Outils : Python (Excel pour vérifier)

Objectif. Comparer plusieurs méthodes de détection, puis décider **avec discernement** quoi faire de chaque valeur suspecte.

> **Rappel du cours**
> **IQR** = Q3 − Q1. Bornes : Q1 − k × IQR et Q3 + k × IQR. Avec k = 1,5 (méthode IQR classique) ; avec k = 3 (variante appelée « Tukey » dans le cours), plus tolérante.
> **Z-score** : Z = (x − x̄) ÷ s. On considère comme aberrantes les valeurs avec |Z| > 3.
> **Box plot** : la boîte représente l'IQR, le trait central la médiane, les moustaches s'arrêtent aux dernières valeurs non aberrantes, les points isolés sont les outliers.
> **Gestion** : remplacer (médiane), supprimer, ou **accepter** la présence d'outliers quand elle est justifiée.

Travail demandé

Q5.1 Pour `montant_dh`, `delai_livraison_jours`, `age_client` et `nb_articles`, calculez Q1, Q3, IQR, les bornes avec k = 1,5 et k = 3, et le nombre d'outliers pour chaque k.

Variable	Q1	Q3	IQR	Bornes k = 1,5	Bornes k = 3	Outliers (1,5 / 3)
montant_dh						
delai_livraison_jours						
age_client						
nb_articles						

Q5.2 Tracez deux box plots : (a) `montant_dh` pour toutes les commandes ; (b) `montant_dh` par catégorie, côte à côte. Quels outliers apparaissent par catégorie sans apparaître globalement, ou l'inverse ? Faut-il détecter globalement ou par groupe ? (Un montant de 2 500 DH est-il aussi suspect en électronique qu'en beauté ?)

Q5.3 Ajoutez les colonnes `z_montant` et `z_age`, marquez les valeurs avec |Z| > 3 et tracez l'histogramme des Z-scores de `montant_dh`. Combien d'outliers trouvez-vous ?

Q5.4 Complétez le **tableau de concordance** pour `montant_dh`. Quelle méthode est la plus sensible, laquelle la plus tolérante ? Laquelle retenez-vous pour cette variable, et pourquoi ?

Méthode	Seuils	Nb d'outliers	Commentaire
Deux écarts-types			
IQR, k = 1,5			
IQR, k = 3 (Tukey)			
|Z| > 3			
Détectées par les 4 méthodes			

Q5.5 Traitement. Pour chaque valeur du registre de la partie 4, choisissez une décision : **(A)** supprimer la ligne, **(B)** remplacer par la médiane, **(C)** conserver et signaler. Règles imposées :

- une valeur **impossible** (âge de 0 ou 130 ans, montant négatif, délai négatif, 0 article) est une erreur : on la corrige ou on la supprime ;

- une valeur **extrême mais plausible** ne se supprime pas automatiquement : on cherche d'abord à la comprendre ;
- chaque décision est justifiée par une phrase.

ID commande	Variable	Valeur	Décision (A/B/C)	Justification

Q5.6 Produisez `commandes_propre.csv`. Recalculez moyenne, médiane, écart-type et étendue de `montant_dh`, `delai_livraison_jours` et `age_client` avant et après traitement. Quels indicateurs ont le plus bougé : moyenne, médiane ou écart-type ? Pourquoi ?

Indicateur	montant avant	montant après	délai avant	délai après	âge avant	âge après
Moyenne						
Médiane						
Écart-type						
Étendue						

Livrable attendu
Tableaux Q5.1, Q5.4, Q5.5 et Q5.6 · box plots et histogramme des Z-scores · `commandes_propre.csv`.

Partie 6 — Mise à l'échelle et détection multivariée

Séance 5 · Durée estimée : 1 h 45 · Barème : 2,5 points · Outils : Python

Objectif. Mettre les variables sur une même échelle, puis détecter des anomalies en regardant **plusieurs variables à la fois**.

Rappel du cours
Standardisation : x′ = (x − moyenne) ÷ écart-type → moyenne 0, écart-type 1, valeurs positives et négatives. **Normalisation min-max** : x′ = (x − min) ÷ (max − min) → plage [0 ; 1]. Ce sont des transformations linéaires : elles changent l'échelle, pas la forme de la distribution.
DBSCAN : clustering par densité. Paramètres : `eps` (rayon de voisinage) et `min_samples`. Les points rattachés à aucun cluster sont du **bruit** (label −1) : des outliers candidats.
Isolation Forest : les anomalies sont « rares et différentes », donc isolées en moins de divisions dans des arbres de décision aléatoires.

```
from sklearn.preprocessing import StandardScaler, MinMaxScaler
```

```
from sklearn.cluster import DBSCAN
from sklearn.ensemble import IsolationForest

X = df[["montant_dh", "delai_livraison_jours", "age_client"]]
X_std = StandardScaler().fit_transform(X)
labels = DBSCAN(eps=..., min_samples=...).fit_predict(X_std)    # -1 = bruit
iso = IsolationForest(contamination=0.03, random_state=42).fit(X_std)
pred = iso.predict(X_std)                                        # -1 = anomalie
```

Travail demandé

Q6.1 Sur `commandes_propre.csv`, standardisez et normalisez (min-max) `age_client`, `montant_dh`, `delai_livraison_jours` et `nb_articles` : d'abord avec les formules « à la main », puis avec `StandardScaler` et `MinMaxScaler`. Vérifiez moyenne ≈ 0 et écart-type ≈ 1 d'un côté, minimum = 0 et maximum = 1 de l'autre. Si un petit écart apparaît entre votre calcul manuel (n − 1) et `StandardScaler`, expliquez-le.

Q6.2 Tracez trois histogrammes côte à côte de `montant_dh` : original, standardisé, normalisé. Qu'est-ce qui change ? Qu'est-ce qui ne change pas ?

Q6.3 Complétez le tableau : pour chaque usage, choisissez standardisation ou normalisation, et justifiez en une phrase.

Usage	Choix	Justification
Régression linéaire ou logistique		
Analyse en composantes principales (ACP)		
Clustering K-Means		
Réseau de neurones		
K-Nearest Neighbors (KNN)		
Détection d'outliers par Z-scores		
Visualisation de données		

Q6.4 Pourquoi standardiser avant DBSCAN ? `montant_dh` se compte en centaines de DH, `delai_livraison_jours` en quelques jours. Illustrez avec deux commandes : calculez la distance euclidienne entre elles (50 DH d'écart et 1 jour d'écart) avant et après standardisation.

Q6.5 **DBSCAN multi-variables.** Utilisez `commandes_nettoye.csv` (fin de la partie 1, **avant** traitement des outliers, avec les manquants numériques remplis) pour tester si l'algorithme retrouve les anomalies que vous avez traitées à la main. Variables : `montant_dh`, `delai_livraison_jours`, `age_client`, standardisées. Testez au moins 4 combinaisons de paramètres, notez les résultats, choisissez une configuration et justifiez-la. Tracez `montant_dh` (X) contre `delai_livraison_jours` (Y), avec les outliers en croix rouges (`marker="x"`).

Essai	eps	min_samples	Nb de clusters	Points de bruit	Observation
1					
2					

Essai	eps	min_samples	Nb de clusters	Points de bruit	Observation
3					
4					

Q6.6 **Isolation Forest** sur les mêmes variables. Testez `contamination` = 0,01 ; 0,03 ; 0,05 et notez le nombre d'anomalies détectées. Récupérez aussi le score d'anomalie (`decision_function`) et affichez les 10 lignes les plus « isolées ».

Q6.7 Comparez les méthodes dans le tableau. Quelles lignes sont détectées par toutes les méthodes ? Quels cas ne sont détectés que par une seule (par exemple une commande dont chaque valeur est normale prise isolément, mais dont la combinaison est rare) ?

Méthode	Lignes signalées	Commentaire
DBSCAN (configuration retenue)		
Isolation Forest (contamination 0,03)		
IQR k = 1,5 (au moins une des 3 variables)		
Vos décisions de la partie 5		
Signalées par les 4 à la fois		

Q6.8 Fiche de synthèse : complétez le tableau comparatif des méthodes de détection vues dans le cours.

Méthode	Nb de variables	Hypothèse de normalité ?	Avantage principal	Limite principale
Deux écarts-types				
Z-score				
IQR / Tukey				
Box plot				
DBSCAN				
Isolation Forest				

Livrable attendu
Tableaux Q6.3, Q6.5, Q6.7, Q6.8 · histogrammes Q6.2 · graphique DBSCAN Q6.5 · réponses rédigées Q6.1 et Q6.4.

Partie 7 — Probabilités et classification

Séance 6 · Durée estimée : 2 h 30 · Barème : 3,5 points · Outils : Python (Excel possible pour 7A)

Objectif. Passer de la description à l'**inférence** : mesurer des risques, mettre à jour une probabilité avec une nouvelle information, classer des messages et estimer avec un échantillon.

Rappel du cours

Probabilité conditionnelle : $P(A \mid B) = P(A \cap B) \div P(B)$.
Théorème de Bayes : $P(A \mid B) = P(B \mid A) \times P(A) \div P(B)$, avec $P(B) > 0$. Probabilités totales : $P(B) = \Sigma P(B \mid A_i) \times P(A_i)$.
Naive Bayes : `MultinomialNB` (comptages ou fréquences de mots), `BernoulliNB` (présence ou absence, 0/1), `GaussianNB` (variables continues normales).
Monte Carlo et loi des grands nombres : plus un échantillon aléatoire est grand, plus sa moyenne se rapproche de celle de la population.

7A. Probabilités conditionnelles et Bayes (commandes_propre.csv)

Q7.1 Calculez P(retour = Oui), puis P(retour = Oui | catégorie) pour chaque catégorie (`pd.crosstab(..., normalize="index")` ou tableau croisé dynamique). Quelle catégorie est la plus à risque ? De combien de points de pourcentage s'écarte-t-elle de la moyenne générale ?

Q7.2 Calculez P(colis endommagé = Oui | entrepôt) pour A, B et C. Pour l'entrepôt C, détaillez le calcul avec $P(A \cap B) \div P(B)$ à partir des effectifs, puis vérifiez avec pandas.

Q7.3 Un colis arrive endommagé : quelle est la probabilité qu'il vienne de l'entrepôt C ?

- (a) calculez P(C), P(endommagé | C) et P(endommagé) (par les probabilités totales) ;
- (b) appliquez le théorème de Bayes ;
- (c) vérifiez en lisant directement P(C | endommagé) dans un tableau croisé ;
- (d) comparez P(C | endommagé) à P(C) : qu'apprend-on en observant un colis endommagé ? Quel entrepôt auditer en premier ?

Q7.4 Comparez P(retour = Oui | colis endommagé = Oui) et P(retour = Oui | colis endommagé = Non). Les événements « retour » et « colis endommagé » sont-ils indépendants ? Justifiez avec les chiffres.

7B. Détection de spam avec Naive Bayes (messages_clients.csv)

Q7.5 Préparation : supprimez les lignes sans message ou sans étiquette (ou justifiez un autre choix), supprimez les doublons, harmonisez `Category`, créez la colonne `Spam` (1 si spam, 0 sinon) et tracez le diagramme en barres des deux classes. Les classes sont-elles équilibrées ? Quelle serait l'accuracy d'un modèle « paresseux » qui répond toujours ham ?

Q7.6 Le théorème de Bayes sur les données : calculez P(spam), P(contient « gratuit » | spam) et P(contient « gratuit » | ham), puis P(spam | contient « gratuit ») par Bayes. Vérifiez par comptage direct (`str.contains(..., case=False)`). Que remarquez-vous ?

Q7.7 Construisez le modèle, puis évaluez-le au-delà de l'accuracy : matrice de confusion, précision et rappel de la classe spam. Comparez avec le modèle paresseux de Q7.5. Quelle erreur coûte le plus cher à MarocShop : classer un vrai client en spam, ou laisser passer un spam ?

```
from sklearn.model_selection import train_test_split
from sklearn.pipeline import Pipeline
from sklearn.feature_extraction.text import CountVectorizer
from sklearn.naive_bayes import MultinomialNB
from sklearn.metrics import confusion_matrix, classification_report

X_train, X_test, y_train, y_test = train_test_split(..., ..., test_size=0.25,
random_state=42)
clf = Pipeline([("vectorizer", CountVectorizer()), ("nb", MultinomialNB())])
clf.fit(..., ...)
print(clf.score(..., ...))
```

Q7.8 Testez le modèle avec 6 messages que vous écrivez : 2 clairement ham, 2 clairement spam, 2 ambigus (un message légitime contenant « gratuit » ou « offre », par exemple). Affichez les prédictions et `predict_proba`, puis expliquez le comportement du modèle avec le théorème de Bayes et les fréquences de mots.

Q7.9 Comparez `MultinomialNB` et `BernoulliNB` (avec `CountVectorizer(binary=True)`) : accuracy et rappel du spam. Pourquoi `GaussianNB` n'est-il pas adapté à ce problème ?

7C. Simulation Monte Carlo

Dans cette partie, la **population** est l'ensemble des montants de `commandes_propre.csv` ; sa moyenne est la « vraie » valeur à retrouver avec peu de données.

Q7.10 Calculez la moyenne et l'écart-type de la population. Puis, avec `np.random.seed(42)` et `np.random.choice(N, size=n, replace=False)`, tirez un échantillon de **20 %**, de **10 %** et de **5 %** ; calculez sa moyenne, son écart-type et l'**erreur relative** |moyenne échantillon − moyenne population| ÷ moyenne population. Pourquoi ne descend-on pas à 0,5 % comme dans le cours ? (Calculez la taille de l'échantillon.)

Échantillon	n	Moyenne	Écart-type	Erreur relative	Remarque
Population (référence)					
20 %					
10 %					
5 %					

```
np.random.seed(42)
population = df["montant_dh"].to_numpy()
n = int(len(population) * 0.10)
idx = np.random.choice(len(population), size=n, replace=False)
sample = population[idx]
# Pour 1 000 répétitions : une boucle for et une liste de moyennes
```

Q7.11 Répétez chaque tirage **1 000 fois** et stockez les moyennes. Tracez l'histogramme des 1 000 moyennes pour 20 %, 10 % et 5 %. Pour chaque taille, calculez la moyenne des erreurs relatives et l'écart-type des moyennes obtenues. Que constatez-vous quand la taille diminue ? Faites le lien avec la loi des grands nombres.

Taille	Moyenne des 1 000 moyennes	Écart-type des moyennes	Erreur relative moyenne
20 %			
10 %			
5 %			

Q7.12 Refaites Q7.10 et Q7.11 avec `age_client` (distribution proche d'une normale) à la place de `montant_dh` (asymétrique). Dans quel cas l'erreur relative est-elle la plus faible ? Le cours affirme que Monte Carlo fonctionne mieux avec des données normales et centrées : vos résultats le confirment-ils ?

Livrable attendu
Tableaux Q7.1 à Q7.4 (avec les calculs) · diagramme Q7.5 · matrice de confusion et rapport Q7.7 · tableau des 6 messages Q7.8 · tableaux et histogrammes Monte Carlo · réponses rédigées.

Partie 8 — Synthèse décisionnelle

Séances 1 à 6 · Durée estimée : 1 h · Barème : 2 points · Outils : Word ou PDF, Excel

Objectif. Transformer vos résultats en décisions : une direction ne lit pas du code, elle lit des constats et des recommandations.

Travail demandé

Q8.1 Rédigez un **rapport de 3 pages maximum** pour la direction de MarocShop :

- contexte et méthode (nettoyage, anomalies repérées, choix de traitement) ;
- au moins **6 constats chiffrés** issus des parties 2 à 7 ;
- **3 recommandations** opérationnelles, classées par priorité et appuyées par un chiffre (à vous de choisir ce que les données justifient : entrepôts, retours par catégorie, délais par ville, filtrage des spams…) ;
- limites de l'analyse.

Q8.2 Dans l'onglet « Synthèse » du classeur Excel, présentez au moins **8 indicateurs clés** (par exemple : nombre de commandes après nettoyage, montant médian, taux de retour global, taux de colis endommagés par entrepôt, nombre de valeurs aberrantes traitées, accuracy et rappel du spam, erreur relative Monte Carlo à 10 %).

Q8.3 Auto-évaluation : listez 3 limites ou risques de votre analyse (corrélation n'est pas causalité, taille de l'échantillon, hypothèses de normalité…) et 2 pistes d'amélioration.

Livrable attendu
Rapport (3 pages max) · onglet « Synthèse » · notebook final exécutable de haut en bas.

Pour aller plus loin (facultatif, sans points)

- Refaire la partie 3 en langage R.
- Améliorer le filtre antispam avec TF-IDF (`TfidfVectorizer`) et comparer.
- Tester si le taux de retour de la catégorie la plus à risque est « significativement » différent des autres (idée de statistique inférentielle).

Annexe A — Aide-mémoire des formules

Notion	Formule	Excel (version FR)	Python
Moyenne	Σ valeurs ÷ n	MOYENNE	.mean()
Médiane	valeur centrale de la série ordonnée	MEDIANE	.median()
Mode	valeur la plus fréquente	MODE.SIMPLE	.mode() / statistics.mode
Étendue	max − min	MAX − MIN	.max() − .min()
Variance (échantillon)	$\Sigma(x - \bar{x})^2 \div (n - 1)$	VAR.S	.var(ddof=1)
Écart-type	√variance	ECARTYPE.STANDARD	.std(ddof=1)
Quartiles, centiles	Q1 = 25 %, Q2 = 50 %, Q3 = 75 % ; C1 à C99	QUARTILE.INCLURE, CENTILE.INCLURE	.quantile() / np.percentile
IQR et bornes	Q3 − Q1 ; Q1 − k·IQR ; Q3 + k·IQR	formules	calcul avec quantile
Deux écarts-types	moyenne ± 2σ	formules	mean() ± 2·std()
Z-score	$(x - \bar{x}) \div s$	CENTREE.REDUITE	calcul manuel ou scipy.stats.zscore
Normalisation min-max	(x − min) ÷ (max − min)	formule	MinMaxScaler
Probabilité conditionnelle	$P(A \cap B) \div P(B)$	tableau croisé dynamique	pd.crosstab(normalize=...)
Théorème de Bayes	$P(B \mid A) \times P(A) \div P(B)$	formule	calcul manuel

Annexe B — Barème sur 20

Partie	Points	Critères principaux
1	3	Classification correcte des variables ; journal d'anomalies complet ; nettoyage justifié et traçable
2	2	Valeurs exactes et concordantes Excel / Python ; choix moyenne ou médiane argumenté
3	2	Variance avec n − 1 ; calcul pas à pas ; analyse de la sensibilité aux valeurs extrêmes
4	2	Percentiles corrects ; registre des valeurs suspectes pertinent ; méthode 2σ et ses limites
5	3	IQR et Z-score corrects ; concordance analysée ; décisions justifiées ; tableau avant / après commenté
6	2,5	Mise à l'échelle correcte ; DBSCAN paramétré et justifié ; Isolation Forest ; comparaison des méthodes
7	3,5	Conditionnelles et Bayes corrects ; Naive Bayes évalué au-delà de l'accuracy ; Monte Carlo répété et interprété
8	2	Rapport clair ; recommandations chiffrées ; indicateurs de synthèse ; limites identifiées
Total	20	À l'intérieur de chaque partie : exactitude des calculs (≈ 50 %), qualité des interprétations (≈ 30 %), présentation et reproductibilité (≈ 20 %)

Annexe C — Conseils de méthode et erreurs fréquentes

- **Gardez le brut intact** et travaillez toujours sur une copie ; notez le nombre de lignes avant et après chaque opération de nettoyage.
- **Variance et écart-type** : pandas divise par n − 1, numpy par n. Précisez toujours `ddof`.
- **Ne supprimez pas une valeur parce qu'elle est extrême** : comprenez-la d'abord. Une valeur impossible est une erreur ; une valeur rare mais plausible est une information.
- **Moyenne et valeurs manquantes** : remplacer par la moyenne une colonne qui contient des valeurs extrêmes introduit un biais ; la médiane est plus robuste.
- **Accuracy trompeuse** : avec des classes déséquilibrées, comparez toujours à un modèle « paresseux » et regardez le rappel de la classe rare.
- **Reproductibilité** : `np.random.seed(42)` et `random_state=42`, et relancez le notebook de haut en bas avant de le rendre.
- **Excel en français** : les noms de fonctions changent (`AVERAGE` devient `MOYENNE`, `MODE.SNGL` devient `MODE.SIMPLE`, `STDEV.S` devient `ECARTYPE.STANDARD`).